

Régression linéaire simple

Postulats

H₁ Linéarité : $E[\varepsilon_i] = 0$

H₂ Homoscédasticité : $Var(\varepsilon_i) = \sigma^2$

H₃ Indépendance : $Cov(\varepsilon_i, \varepsilon_j) = 0$

H₄ Normalité : $\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$

Modèle

$$\begin{aligned} E[Y_i|x_i] &= \beta_0 + \beta_1 x_i \\ Var(Y_i|x_i) &= \sigma^2 \\ Y_i|x_i &\stackrel{H_4}{\sim} \mathcal{N}(\beta_0 + \beta_1 x_i, \sigma^2) \end{aligned}$$

Estimation des paramètres

$$\begin{aligned} \hat{\beta}_0 &= \bar{Y} - \hat{\beta}_1 \bar{x} \\ \hat{\beta}_1 &= \frac{\sum_{i=1}^n x_i Y_i - \bar{Y} \sum_{i=1}^n x_i}{\sum_{i=1}^n x_i^2 - \bar{x} \sum_{i=1}^n x_i} = \frac{\sum_{i=1}^n (x_i - \bar{x}) Y_i}{S_{XX}} \end{aligned}$$

Estimation de σ^2

$$\hat{\sigma}^2 = s^2 = \frac{\sum_{i=1}^n \varepsilon_i^2}{n - p'} = \frac{\sum_{i=1}^n (Y_i - \hat{Y}_i)^2}{n - 2}$$

Propriété des estimateurs

$$\begin{aligned} E[\hat{\beta}_1] &= \beta_1, \quad Var(\hat{\beta}_1) = \frac{\sigma^2}{S_{XX}} \\ \hat{\beta}_1 &\stackrel{H_4}{\sim} \mathcal{N}\left(\beta_1, \frac{\sigma^2}{S_{XX}}\right) \\ E[\hat{\beta}_0] &= \beta_0, \quad Var(\hat{\beta}_0) = \sigma^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{S_{XX}} \right) \\ \hat{\beta}_0 &\stackrel{H_4}{\sim} \mathcal{N}\left(\beta_0, \sigma^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{S_{XX}} \right)\right) \\ Cov(\hat{\beta}_0, \hat{\beta}_1) &= -\frac{\bar{x} \sigma^2}{S_{XX}} \end{aligned}$$

Tests d'hypothèse sur les paramètres

$$\begin{aligned} H_0 : \hat{\beta} &= \theta_0, \quad H_1 : \hat{\beta} \neq \theta_0 \\ t_{obs} &= \frac{\hat{\beta} - \theta_0}{\sqrt{Var(\hat{\beta})}} \sim T_{n-2} \\ \text{On Rejette } H_0 &\text{ si } t_{obs} > |t_{n-2}(1 - \frac{\alpha}{2})| \end{aligned}$$

Intervalle de confiance

Pour la droite de régression ($E[Y_0|x_0]$)

$$\begin{aligned} \text{Sachant que } E[Y_0|x_0] &= \beta_0 + \beta_1 x_0, \text{ on a l'IC suivant} \\ \left[\hat{Y}_0 \pm t_{n-2} \left(1 - \frac{\alpha}{2} \right) \sqrt{s^2 \left(\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{XX}} \right)} \right] \end{aligned}$$

Pour la prévision de Y_0

$$\begin{aligned} \text{Sachant que } Y_0 &= \beta_0 + \beta_1 x_0 + \varepsilon, \text{ on a l'IC suivant} \\ \hat{Y}_0 \pm t_{n-2} \left(1 - \frac{\alpha}{2} \right) \sqrt{s^2 \left(1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{XX}} \right)} \end{aligned}$$

Analyse de la variance (ANOVA)

Source	dl	SS	MS	F
Model	p	$\sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2$ (SSR)	SSR/dl_1 (MSR)	$\frac{MSR}{MSE}$
Residual error	$n - p'$	$\sum_{i=1}^n (Y_i - \hat{Y}_i)^2$ (SSE)	SSE/dl_2 (MSE = s^2)	
Total	$n - 1$	$\sum_{i=1}^n (Y_i - \bar{Y})^2$ (SST)		

Où p est le nombre de variables explicatives dans le modèle.

Coefficient de détermination

$$\begin{aligned} R^2 &= \frac{SSR}{SST} = 1 - \frac{SSE}{SST} \\ \text{On a aussi la relation suivante avec } F_{obs} : \\ F &= \frac{R^2}{1 - R^2} \cdot \frac{n - p'}{p} \end{aligned}$$

Test F de Fisher pour la validité globale de la régression

On rejette $H_0 : \beta_1 = \beta_2 = \dots = \beta_p = 0$ si

$$F_{obs} = \frac{MSR}{MSE} \geq F_{n, n-p'}(1 - \alpha)$$

où p est le nombre de variables explicatives dans le modèle (régression linéaire simple, $p = 1$ et $p' = p + 1$).

Distribution d'un résidu ε

$$\begin{aligned} E[\hat{\varepsilon}_i] &= 0, \quad Var(\hat{\varepsilon}_i) = \sigma^2(1 - h_{ii}) \\ \text{où } h_{ii} &= \frac{1}{n} + \frac{(\bar{x} - x_i)^2}{S_{XX}}. \\ \text{On peut aussi prouver que} \\ Cov(\hat{\varepsilon}_i, \hat{\varepsilon}_j) &= -\sigma^2 \left(\frac{1}{n} + \frac{(x_i - \bar{x})(x_j - \bar{x})}{S_{XX}} \right) \end{aligned}$$

Vérification des postulats

Les résidus studentisés sont définis par

$$r_i = \frac{\hat{\varepsilon}_i}{\sqrt{s^2(1 - h_{ii})}}$$

Linéarité

- graphique $Y_i|x_i$
- graphique $\hat{\varepsilon}_i|\hat{Y}_i$
- graphique $\hat{\varepsilon}_i|x_i$

Les deux derniers graphique doivent être centrés à 0 et d'allure aléatoire.

Homoscédasticité

- Graphique $r_i|\hat{Y}_i$: la dispersion des résidus doit être constante, pas de forme d'entonnoir ou de résidus absolus supérieurs à 3.

Indépendance

- Graphique $r_i|i$: si il y a un *pattern*, présence d'auto-corrélation (le postulat H_3 n'est donc pas respecté).

Normalité

- Histogramme des r_i
- Q-Q Plot Normal : les résidus du modèle doivent suivre la droite des quantiles normaux théoriques.

2 Régression linéaire multiple

Le modèle et ses propriétés

$$\begin{aligned} \mathbf{Y}_{n \times 1} &= \mathbf{X}_{n \times p'} \boldsymbol{\beta}_{p' \times 1} + \boldsymbol{\varepsilon}_{n \times 1} \\ E[\mathbf{Y}] &= \mathbf{X}\boldsymbol{\beta}, \text{Var}(\mathbf{Y}) = \sigma^2 \mathbf{I}_{n \times n} \\ \mathbf{Y} &\stackrel{H_4}{\sim} \mathcal{N}_n(\mathbf{X}\boldsymbol{\beta}, \sigma^2 \mathbf{I}_{n \times n}) \end{aligned}$$

Paramètres du modèle

Estimation et propriétés des paramètres

$$\begin{aligned} \hat{\boldsymbol{\beta}} &= (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y} \\ E[\hat{\boldsymbol{\beta}}] &= \boldsymbol{\beta}, \text{Var}(\hat{\boldsymbol{\beta}}) = \sigma^2 (\mathbf{X}^\top \mathbf{X})^{-1} \\ \hat{\boldsymbol{\beta}} &\stackrel{H_4}{\sim} \mathcal{N}_p(\boldsymbol{\beta}, \sigma^2 (\mathbf{X}^\top \mathbf{X})^{-1}) \end{aligned}$$

Intervalle de confiance sur les paramètres

$$\begin{aligned} \text{var}[\beta_j] &= \sigma^2 v_{jj} \\ \beta_j &\in \left[\hat{\beta}_j \pm t_{n-p'} \left(1 - \frac{\alpha}{2} \right) \sqrt{s^2 v_{jj}} \right] \\ \text{où } v_{jj} &\text{ est l'élément } (j, j) \text{ de la matrice } (\mathbf{X}^\top \mathbf{X})^{-1}. \end{aligned}$$

Estimation de σ^2

$$\hat{\sigma}^2 = s^2 = \frac{\hat{\boldsymbol{\varepsilon}}^\top \hat{\boldsymbol{\varepsilon}}}{n - p'}$$

Il peut être démontré que cette estimateur est sans biais et indépendant de $\hat{\boldsymbol{\beta}}$

Test d'hypothèse sur un paramètre du modèle

On rejette $H_0 : \beta_j = 0$ si

$$|t_{obs,j}| = \frac{\hat{\beta}_j}{\sqrt{s^2 v_{jj}}} > t_{n-p'} \left(1 - \frac{\alpha}{2} \right)$$

Propriétés de la droite de régression

$$\begin{aligned} \hat{\mathbf{Y}} &= \mathbf{X}\hat{\boldsymbol{\beta}} & \hat{\boldsymbol{\varepsilon}} &= \mathbf{Y} - \hat{\mathbf{Y}} \\ &= \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y} & &= (\mathbf{I}_n - \mathbf{H})\mathbf{Y} \\ &= \mathbf{H}\mathbf{Y} & & \end{aligned}$$

où $\mathbf{H} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top$ est la *hat matrix*.

On a aussi que

$$\begin{aligned} E[\hat{\mathbf{Y}}] &= \mathbf{X}\boldsymbol{\beta}, \text{Var}(\hat{\mathbf{Y}}) = \sigma^2 \mathbf{H} \\ \hat{\mathbf{Y}} &\stackrel{H_4}{\sim} \mathcal{N}_n(\mathbf{X}\boldsymbol{\beta}, \sigma^2 \mathbf{H}) \end{aligned}$$

Pour les résidus de la droite de régression, on a

$$\begin{aligned} E[\hat{\boldsymbol{\varepsilon}}] &\stackrel{H_1}{=} \mathbf{0}, \text{Var}(\hat{\boldsymbol{\varepsilon}}) = \sigma^2 (\mathbf{I}_{n \times n} - \mathbf{H}) \\ \hat{\boldsymbol{\varepsilon}} &\stackrel{H_4}{\sim} \mathcal{N}_n(\mathbf{0}, \sigma^2 (\mathbf{I}_{n \times n} - \mathbf{H})) \end{aligned}$$

Matrice de projection

Les matrices \mathbf{H} et $\mathbf{I}_n - \mathbf{H}$ peuvent être vues comme des matrices de projection. Ces deux opérateurs possèdent plusieurs propriétés :

- $\mathbf{H}^\top = \mathbf{H}$ (symétrie)
- $\mathbf{H}\mathbf{H} = \mathbf{H}$ (idempotence)
- $\mathbf{H}\mathbf{X} = \mathbf{X}$
- $(\mathbf{I}_n - \mathbf{H}) = (\mathbf{I}_n - \mathbf{H})^\top$ (symétrie)
- $(\mathbf{I}_n - \mathbf{H})(\mathbf{I}_n - \mathbf{H}) = (\mathbf{I}_n - \mathbf{H})$
- $(\mathbf{I}_n - \mathbf{H})\mathbf{X} = \mathbf{0}$
- $(\mathbf{I}_n - \mathbf{H})\mathbf{H} = \mathbf{0}$

Intervalle de confiance pour la prévision

Théorème de Gauss-Markov

Selon les postulats H_1 à H_4 , l'estimateur

$$\mathbf{a}^\top \hat{\boldsymbol{\beta}} = \mathbf{a}^\top (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}$$

est le meilleur estimateur pour $\mathbf{a}^\top \boldsymbol{\beta}$

(BLUE : *Best linear unbiased estimator*).

I.C. pour la prévision de la valeur moyenne $E[Y|\mathbf{X}^*]$

$$\left[\mathbf{X}^{*\top} \hat{\boldsymbol{\beta}} \pm t_{n-p'} \left(1 - \frac{\alpha}{2} \right) \sqrt{s^2 \mathbf{X}^{*\top} (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^*} \right]$$

I.C. pour la valeur prédite $\hat{Y}|\mathbf{X}^*$

$$\left[\mathbf{X}^{*\top} \hat{\boldsymbol{\beta}} \pm t_{n-p'} \left(1 - \frac{\alpha}{2} \right) \sqrt{s^2 \left(1 + \mathbf{X}^{*\top} (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^* \right)} \right]$$

Analyse de la variance

Tableau ANOVA

- On utilise le même tableau ANOVA qu'en régression linéaire simple.
- $SSR_{\text{régression}} = \sum_{i=1}^p SSR_i$, où SSR_i représente le SSR individuel de la variable explicative i calculé par R. On peut ensuite trouver MSR et la statistique F_{obs} .

Test F pour la validité globale de la régression

Même test qu'en régression linéaire simple.

Test F partiel pour la réduction du modèle

Avec $k < p$, on va rejeter

$$H_0 : Y_i = \beta_0 + \beta_1 x_{i1} + \dots + \beta_{ik} \quad (\text{modèle réduit})$$

Pour

$$H_1 : Y_i = \beta_0 + \beta_1 x_{i1} + \dots + \beta_{ip} \quad (\text{modèle complet})$$

Si

$$F_{\text{obs}} = \frac{(SSE^{(0)} - SSE^{(1)}) / \Delta dl}{SSE^{(1)} / (n - p')} \geq F_{p-k, n-p'}(1 - \alpha)$$

où $\Delta dl = p - k$, $SSE^{(0)}$ pour le modèle réduit (H_0) et $SSE^{(1)}$ pour le modèle complet (H_1).

Multicollinéarité

Problèmes potentiels

- Instabilité de $(\mathbf{X}^\top \mathbf{X})^{-1}$, i.e. une petite variation de Y peut changer de grandes variations en $\hat{\boldsymbol{\beta}}$ et \hat{Y} ;
- $\hat{\beta}_i$ de signes contre-intuitif;
- $\text{Var}(\hat{\beta}_i)$ et $\text{Var}(\hat{Y})$ très grandes;
- Les méthodes de sélection de variable ne concordent pas;
- Conclusions erronées sur la significativité de certains paramètres, malgré une forte corrélation avec Y .

Détection

- Si r_{ij} dans la matrice de corrélation $\mathbf{X}^{*\top} \mathbf{X}^*$ est élevée, où $\mathbf{X}^* = \begin{bmatrix} \frac{x_1 - \bar{x}_1}{s_1} & \dots & \frac{x_p - \bar{x}_p}{s_p} \end{bmatrix}_{1 \times p}$
- Si le facteur d'influence de la variance (VIF_j) est élevé, où

$$VIF_j = \frac{1}{1 - R_j^2}$$

avec R_j^2 le coefficient de détermination de la régression ayant comme variable réponse le j^{e} variable et les $(j - 1)$ autres variables exogènes en *input*.

- La variance de $\hat{\beta}_j$ s'exprime en fonction du VIF comme suit :

$$\text{Var}(\hat{\beta}_j) = \frac{\sigma^2}{(\mathbf{X}^{*\top} \mathbf{X}^*)_{jj}} VIF_j$$

Solution

- On retire les variables ayant un VIF élevé (une à la fois)
- On combine des variables exogènes redondantes

Validation du modèle et des postulats

Linéarité

- On trace les graphiques à variable ajoutée ($\hat{\varepsilon}_Y | \mathbf{X}_{-j}$ en fonction de $\hat{\varepsilon}_{x_j | \mathbf{X}_{-j}}$).
- Ces graphiques doivent normalement donner une droite de pente β_j .
 - Si le graphique ressemble à un graphique de résidus normaux, x_j est inutile.
 - Si il y a une courbe, x_j est non-linéaire.

Homogénéité des variances

- Graphique $r_i | \hat{Y}_i$

Indépendance entre les observations

- Graphique $\hat{\varepsilon}_i | i$
- Test de Durbin-Watson (pas à l'examen)

3 Sélection de modèle et régression régularisée

En présence de beaucoup de variable exogènes, on court le danger d'en garder trop ou pas assez

- Trop** : On augmente inutilement la variance des estimations($\hat{\boldsymbol{\beta}}$)
- Moins** : On augmente inutilement le biais des estimations($\hat{\boldsymbol{\beta}}$)

Critères de comparaison classiques

- › Coefficient de détermination (pour mesurer la qualité globale du modèle) :

$$R_2 = \frac{SSR}{SST}$$

Si on ajoute une variable exogène, il est certain que R^2 augmentera, on utilise donc ce critère pour valider si la régression est utile pour prédire Y , mais pas pour critère de sélection des variables exogènes.

- › Coefficient de détermination ajusté :

$$R_a^2 = \frac{SSE/p}{SST/(n-1)} = \frac{MSE}{MST}$$

Ce critère permet de valider l'ajout de nouvelles variables exogènes.

Ces deux critères sont inutiles pour comparer des modèles avec des transformations différentes et pour des modèles avec/sans ordonnée à l'origine.

Méthode basées sur la puissance de prévision

Ce critère maximise l'habileté du modèle à prédire de nouvelles données.

Principe de la validation croisée

- Pour $i = 1, \dots, n$,
 - Enlever la i^e observation du jeu de données.
 - Estimer les paramètres du modèle à partir des $n - 1$ données restantes.
 - Prédire Y_i à partir de x_i et du modèle obtenu en 2, noté $\hat{Y}_{i,-i}$
- Calculer la somme des carrés des erreurs de prévision $PRESS = \sum_{i=1}^n (Y_i - \hat{Y}_{i,-i})^2$

On cherche à minimiser le PRESS ou à maximiser le coefficient de détermination de prévision :

$$R_p^2 = 1 - \frac{PRESS}{SST}$$

Les résidus PRESS

Il est possible de trouver la statistique PRESS sans devoir calculer n régressions :

$$PRESS = \sum_{i=1}^n \left(\frac{\varepsilon_i}{1 - h_{ii}} \right)^2$$

Échantillon de test et validation croisée par k ensemble

- Pour $k = 1, \dots, K$,
 - Enlever le k^e ensemble du jeu de donnée.
 - Estimer les paramètres du modèle à partir des données des $k - 1$ échantillons restants.
 - Prédire les observations du k^e ensemble ($\hat{Y}_{i,-k}$) et calculer

$$MSEP_k = \frac{1}{n_k} \sum_{i \in \text{group } k} (Y_i - \hat{Y}_{i,-k})^2$$
- Calculer la moyenne des sommes des carrés des erreurs de prévision $\frac{1}{K} \sum_{k=1}^K MSEP_k$

On choisit le modèle qui minimise $\frac{1}{K} \sum_{k=1}^K MSEP_k$

Le C_p de Mallows

$$C_p = p' + \frac{(s_p^2 - \hat{\sigma}^2)(n - p')}{\hat{\sigma}^2} = \frac{SSE}{\hat{\sigma}^2} + 2p' - n$$

On cherche le modèle pour lequel $C_p \approx p'$

Critère d'information d'akaike et critère bayésien de Schwarz

- › Ce critère est le plus utilisé dans la pratique et permet d'évaluer la qualité de l'ajustement d'un modèle.

$$AIC = n \cdot \ln \left(\frac{SSE}{n} \right) + 2p'$$

AIC prend en compte à la fois la qualité des prédictions du modèle et sa complexité.

- › BIC est similaire à AIC, mais la pénalité des paramètres dépend de la taille de l'échantillon. On cherche à minimiser ces 2 critères.

$$BIC = n \cdot \ln \left(\frac{SSE}{n} \right) + \ln(n)p'$$

Méthode algorithmiques

Méthode d'inclusion (forward)

- On commence avec le modèle le plus simple (i.e. $\hat{Y}_i = \beta_0$)
- On essaie d'ajouter la variable qui, en l'incluant dans le modèle, permet de réduire le plus le SSE du modèle.
- On valide si la variable diminue de façon significative les résidus avec un test F , où

$$F_{obs} = \frac{SSE_{\text{petit modèle}} - SSE_{\text{grand modèle}}}{SSE_{\text{grand modèle}} / (n - p')}$$
 On ajoute la variable au modèle si $F_{obs} > F_{1,n-p'}(1 - \alpha)$
- On répète jusqu'à ce qu'aucune variable ne vaille la peine d'être ajoutée.

Méthode d'exclusion (backward)

- On débute avec le modèle complet
- On veut enlever la variable exogène qui, en l'excluant du modèle, permet de minimiser l'augmentation du SSE de la régression.
- Même test F qu'à l'étape 3 de la méthode *forward*, sauf qu'on enlève la variable seulement si

$$F_{obs} < F_{1,n-p'}(1 - \alpha)$$
- On répète jusqu'à ce qu'aucune variable ne vaille la peine d'être enlevée.

Méthode pas à pas (step-wise)

- On débute avec la méthode d'inclusion
- Après l'ajout d'une variable au modèle, on effectue la méthode d'exclusion pour les variables qui sont actuellement dans le modèle (on remet constamment le modèle en question).

4 Modèles linéaires généralisés (GLM)

Famille exponentielle linéaire

Définition

Une loi de probabilité fait partie de la famille exponentielle linéaire si

- On peut exprimer la fonction de densité (ou masse) de probabilité comme

$$f(y; \theta, \phi) = \exp \left(\frac{y\theta - b(\theta)}{a(\phi)} + c(y; \phi) \right)$$

où θ est le paramètre canonique et ϕ est le paramètre de dispersion.

- la fonction c ne dépend pas du paramètre θ .
- Le support de Y ne dépend pas des paramètres θ ou ϕ .

Propriétés

Soit $\mu = b(\theta) = \frac{\partial}{\partial \theta} b(\theta)$ et $V(\mu) = \ddot{b}(\theta) = \frac{\partial^2}{\partial \theta^2} b(\theta)$. Alors, si Y fait partie de la famille exponentielle linéaire, on peut exprimer l'espérance et la variance comme

$$E[Y] = b(\theta) = \mu$$

$$\text{Var}(Y) = a(\phi) \ddot{b}(\theta) = a(\phi) V(\mu)$$

Lemme de la Log-vraisemblance

Soit $\ell(\theta, \phi; Y) = \ln f(y; \theta, \phi)$ la log-vraisemblance. Alors,

$$E \left[\frac{\partial}{\partial \theta} \ell(\theta, \phi; Y) \right] = 0$$

et

$$E \left[\left(\frac{\partial}{\partial \theta} \ell(\theta, \phi; Y) \right)^2 \right] = -E \left[\frac{\partial^2}{\partial \theta^2} \ell(\theta, \phi; Y) \right]$$

Fonction de lien

Soit $\eta = \mathbf{X}\beta$. La fonction de lien est la transformation qu'on applique à η afin de limiter le support de Y .

Lien logistique $\eta = \ln \left(\frac{\mu}{1-\mu} \right) \leftrightarrow \mu = \frac{e^\eta}{1+e^\eta}$

Lien probit $\eta = \Phi^{-1}(\mu) \leftrightarrow \mu = \Phi(\eta)$

Lien log-log complémentaire $\eta = \ln(-\ln(1-\mu)) \leftrightarrow \mu = 1 - e^{-e^\eta}$

Lien canonique $\eta = \theta$

Estimation des paramètres

- On estime $\hat{\beta}$ avec la méthode du maximum de vraisemblance (EMV ou MLE en anglais)

- L'EMV est cohérent, i.e.

$$\hat{\beta} \xrightarrow{n \rightarrow \infty} \beta$$

- L'estimateur a une normalité asymptotique, i.e.

$$\hat{\beta} \sim \mathcal{N} \left(\beta, \frac{\mathcal{I}(\beta)^{-1}}{n} \right)$$

où $\mathcal{I}(\beta)_{(p' \times p')}$ est la matrice d'information de Fisher :

$$\begin{aligned} \mathcal{I}(\beta) &= E \left[\dot{\ell}(\beta; Y_1, \dots, Y_n) \dot{\ell}(\beta; Y_1, \dots, Y_n)^\top \right] \\ &= -E \left[\ddot{\ell}(\beta; Y_1, \dots, Y_n) \right] \end{aligned}$$

- On peut estimer la matrice d'information de Fisher avec l'information observée :

$$\mathcal{I}(\hat{\beta}) = - \sum_{i=1}^n \frac{\partial^2}{\partial \beta^2} \ell(\beta; Y_i) \Big|_{\hat{\beta}}$$

Algorithme de Newton-Raphson

L'objectif est de trouver $\hat{\beta}$ qui maximise $\ell(\hat{\beta})$, ce qui revient à trouver $\dot{\ell}(\hat{\beta}) = 0$. On utilise l'approximation de Taylor de premier ordre dans l'algorithme :

- Choisir des valeurs de départ pour le vecteur $\hat{\beta}^{H_0}$

- Pour $k = 1, 2, \dots$

$$(2.1) \quad \hat{\beta}^{(k)} = \hat{\beta}^{(k-1)} \mathcal{I} \left\{ \ddot{\ell}(\hat{\beta}^{(k-1)}) \right\}^{-1} \dot{\ell}(\hat{\beta}^{(k-1)})$$

- (2.2) Si $|\dot{\ell}(\hat{\beta}^{(k)})| < \varepsilon$, on converge vers les paramètres optimaux pour le modèle et on arrête.

- (2.3) Répéter les étapes (2.1) et (2.2) jusqu'à une convergence.

Méthode du score de Fisher

Cette méthode est la même que l'algorithme de Newton-Raphson, à l'exception qu'on remplace $\mathcal{I} \left\{ \ddot{\ell}(\hat{\beta}) \right\}$ par $E \left[\ddot{\ell}(\hat{\beta}) \right]$ à l'étape (2.1)

Statistique de Wald

Test d'hypothèse pour tester $H_0 : \beta_j = 0, H_1 : \beta_j \neq 0$. On a que

$$Z = \frac{\hat{\beta}_j}{\sqrt{\text{Var}(\hat{\beta}_j)}} \sim \mathcal{N}(0, 1)$$

On rejette donc H_0 si $Z > z_{1-\frac{\alpha}{2}}$.

Test du rapport de vraisemblance